
Geração de imagens artificiais e extração de
características latentes aplicadas à classificação de
imagens

Gabriela Salvador Thumé

SERVIÇO DE PÓS-GRADUAÇÃO DO ICMC-USP

Data de Depósito:

Assinatura: _____

Geração de imagens artificiais e extração de características latentes aplicadas à classificação de imagens

Gabriela Salvador Thumé

Orientador: *Prof. Dr. Moacir Pereira Ponti Junior*

Monografia apresentada ao Instituto de Ciências
Matemáticas e de Computação - ICMC-USP, para
o Exame de Qualificação, como parte dos
requisitos para obtenção do título de Mestre em
Ciências - Ciências de Computação e Matemática
Computacional.

USP – São Carlos
Fevereiro de 2015

Resumo

A sequência canônica de etapas de processamento de imagens inclui aquisição, pré-processamento, segmentação, extração de características (ou representação e descrição), transformação e reconhecimento. Apesar da grande variedade de métodos disponíveis, a classificação de imagens é comumente tratada apenas considerando um subconjunto destas etapas, em especial a extração de características e o reconhecimento, sendo as demais muitas vezes negligenciadas. Enquanto isso, alguns estudos encontraram evidências de que a preparação das imagens, por meio da especificação cuidadosa da aquisição, pré-processamento e segmentação, pode impactar significativamente o resultado final da classificação. Imagens obtidas de diferentes fontes, como câmeras pessoais, microscopia, telescopia e tomografia, possuem características que podem ser exploradas para melhorar a descrição dos objetos de interesse. Assim, é proposta a melhoria da classificação de imagens utilizando métodos de pré-processamento. Entre as possibilidades de melhorias estão: o uso de realce e restauração para a extração de características latentes, isto é, características não visíveis na imagem original; aprendizagem das características latentes por meio de redes neurais de convolução e máquinas de Boltzmann restritas; e o uso de geração de imagens aleatórias, de forma a promover o balanceamento de bases de dados cujo número de exemplos de cada classe é desbalanceado. Esta dissertação possui resultados preliminares que demonstram o potencial da pesquisa e pretende contribuir com a área, investigando métodos que permitam obter melhores espaços de características.

Porque deep learning? Mais descritores de forma e textura (dependentes da base) Explícitar melhor o comportamento do SMOTE x ACC Bases maiores Algoritmos genéticos para geração de imagens artificiais?

Abstract

melhorar muito o abstract

The canonical steps of digital image processing can be summarized as acquisition, preprocessing, segmentation, feature extraction, transformation and recognition. Although the large number of methods available for image classification, only a subset of those steps are explored, specially related to feature extraction and recognition. The remaining steps are generally neglected. Meanwhile, some studies found evidence that image preparation — by means of an accurate specification of the acquisition, preprocessing and segmentation steps — can improve the classification results. Images captured from different kinds of sources like personal cameras, microscope, telescope and tomography, have features that can be explored to extend the description of objects. Therefore, we propose to improve image classification by using preprocessing methods. Among the possibilities for improvements we can highlight: using both image enhancement and restoration to extract latent features — non-visible characteristics in the original image; latent features learning by means of convolutional neural networks and restricted Boltzmann machines; and synthesis of random artificial images, to be used for database balancing when the number of samples from each class is originally unbalanced. This research has preliminary results which points to its potential. It aims to contribute to the research area by investigating methods to improve image classification while obtaining better feature spaces.

Lista de Figuras

1.1	Etapas canônicas do reconhecimento de padrões desde a aquisição da imagem até sua posterior classificação.	3
2.1	Visualização pixelizada de uma imagem da base COREL-1000.	10
2.2	Sobre a imagem RGB de entrada foram realizadas operações de borramento, realce e de equalização de histograma. A imagem à direita é resultante dessas operações.	11
2.3	Exemplo de filtragem gaussiana como operação de pré-processamento. . . .	13
2.4	A imagem original, já em escala de cinza, foi realçada utilizando o método <i>unsharp masking</i>	15
2.5	Conversão para a escala de cinza com os métodos de Intensidade e MSB. .	18
2.6	Características latentes de algas verdes.	20
2.7	Componentes típicos de uma camada de uma rede neural de convolução. .	23
3.1	Base de imagens COREL-1000.	31
4.1	Geração de imagens artificiais para o rebalanceamento de classes.	36
4.2	Classes “praia” e “montanha” da base de imagens COREL-1000.	38
4.3	Resultado obtido com a operação de combinação apresentada na Figura 4.1.	39
4.4	Piores resultados, obtidos com a adição de ruído.	40
4.5	Simples replicação de exemplos sem realizar nenhuma operação.	41

Lista de Siglas

ACC	Auto-correlograma de cor
BIC	Classificação de pixels de borda e interior
CCV	Vetor de coerência de cor
CNN	Rede neural de convolução
GCH	Histograma de cor global
KNN	K-vizinhos próximos
MSB	Bits mais significativos
RBM	Máquina de Boltzmann restrita
RGB	Sistema de cores vermelho, verde e azul
SMOTE	<i>Synthetic Minority Over-sampling Technique</i>

Sumário

1	Introdução	1
1.1	Contextualização	4
1.2	Relevância e hipóteses	4
1.3	Objetivos	5
1.4	Estrutura do documento	7
2	Fundamentos	9
2.1	Considerações iniciais	9
2.2	Pré-processamento de imagens	10
2.2.1	Filtragem espacial e convolução	12
2.2.2	Deconvolução	13
2.2.3	Realce de imagens	14
2.2.4	Restauração	16
2.2.5	Quantização	17
2.3	Extração de características	17
2.4	Características latentes	19
2.5	Deep learning	21
2.5.1	Redes de convolução	22
2.6	Máquinas de Boltzmann restritas	24
2.7	Desbalanceamento de classes	25
2.7.1	Sobreamostragem	26
2.7.2	Subamostragem	27
2.8	Considerações finais	27
3	Proposta	29
3.1	Considerações iniciais	29
3.2	Metodologia	29
3.3	Resultados esperados	33
3.4	Atividades e cronograma previsto	33
3.5	Considerações finais	34

4 Resultados Preliminares	35
4.1 Considerações iniciais	35
4.2 Descrição do experimento	35
4.2.1 Fluxo de operações	37
4.2.2 Geração das imagens artificiais	37
4.3 Resultados	38
4.4 Trabalhos futuros	41
4.5 Considerações finais	42
Referências Bibliográficas	43

Introdução

A tarefa de classificação de imagens consiste em predizer corretamente uma imagem como pertencente a uma classe previamente determinada. Um exemplo prático é a classificação da imagem de um *oceano* como parte de uma classe denominada *praia*. Uma das formas de definir que certa imagem pertence à uma classe é especificar todas as regras que a caracterizam. Porém, na maioria dos casos isso é impossível. Considere imagens coloridas, com três canais de cores e de tamanho 256×256 pixels. Cada um desses 65536 pixels pode ser representado por 256^3 combinações discretas de cores. Essa complexidade pode ser reduzida ao utilizar métodos de extração de características, os quais visam representar uma imagem com um número menor de valores vetoriais. Utilizando-se tal representação, pode-se desenvolver programas de computador que consigam definir e identificar a qual classe pertence uma imagem, sem a necessidade de se codificar todas as regras possíveis, por meio de algoritmos de aprendizado de máquina.

Os algoritmos de aprendizado de máquina possuem a capacidade de generalização, crucial para classificar novos exemplos não contidos na base de imagens originalmente utilizada para treinamento. Assim, esses algoritmos aprendem a determinar a classe correta para imagens de entrada. Em uma etapa posterior pode-se validar esse aprendizado, aplicando o algoritmo a novos exemplos.

As aplicações de reconhecimento de padrões em imagens possuem aspectos particulares para cada aplicação. Apesar da grande variedade de extratores de características disponíveis, nem sempre é possível resolver o problema de maneira satisfatória. Isso porque existem conjuntos de características que dificultam a diferenciação entre as classes. Um

dos objetivos da área de aprendizado de máquina é encontrar quais são essas características que melhor discriminam as classes.

Em muitos casos, despende-se o maior esforço dessa tarefa ao operar no espaço de características já obtidas. Comumente são utilizadas transformações do espaço ou sistemas de classificação complexos que possam lidar com as deficiências das características extraídas. No entanto, imagens obtidas de diferentes fontes, como imagens naturais, de microscopia, telescopia e tomografia, possuem características que podem ser exploradas além dos métodos clássicos. É importante investigar métodos de processamento e preparação de imagens antes da extração dessas características. O uso desses métodos pode revelar *características latentes*, não visíveis nas imagens originais. O objetivo desta dissertação é encontrar tais características latentes que possam melhor descrever certas classes do problema. Um exemplo visual será apresentado na Seção 2.4.

Considerando que é comum realizar a extração de características a partir da imagem original, sem preocupação com a preparação da imagem, o enfoque desse estudo é na etapa de pré-processamento, destacada na Figura 1.1. Esta ilustra as etapas canônicas do reconhecimento de padrões desde a aquisição da imagem até sua posterior classificação. As etapas de pré-processamento e segmentação — apresentadas em destaque — são normalmente pouco exploradas, quando comparadas com as etapas posteriores.

Atualmente, o estado da arte de extração e classificação de imagens corresponde ao uso de redes neurais de convolução, conhecidas por CNN (Schmidhuber, 2014). Essas redes são compostas por camadas de neurônios que têm por objetivo aprender quais são as melhores características que diferenciam as classes de imagens. O aprendizado, nesse caso, corresponde ao ajuste dos parâmetros para reduzir a diferença entre a saída esperada — classe verdadeira — e a produzida. Dessa forma, tais redes aprendem quais são as características latentes nas imagens de entrada. As redes neurais são discutidas na Seção 2.5, onde as máquinas de Boltzmann restritas (RBM) também são apresentadas. A representação das imagens de entrada, aprendida pela etapa de treinamento da RBM, será utilizada para definir quais imagens são relevantes para o aprendizado ou não. De certa forma essas técnicas produzem versões processadas das imagens de entrada, indicando que os filtros aprendidos são os que melhor diferenciam as classes de imagens.

O desbalanceamento de classes também se apresenta como um obstáculo para que a classificação de imagens seja satisfatória. Esse problema é caracterizado pela diferença entre o número de exemplos disponíveis para cada classe. Muitos métodos de transformação do espaço de características e de classificação assumem que as classes da base estão平衡adas, o que nem sempre é verdade. Portanto, além de realizar pré-processamento

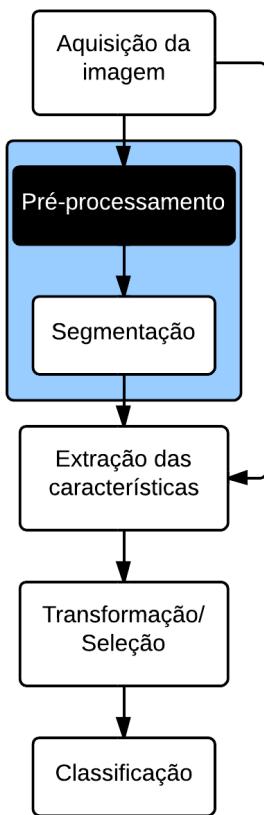


Figura 1.1: Etapas canônicas do reconhecimento de padrões desde a aquisição da imagem até sua posterior classificação. As etapas de pré-processamento e segmentação — apresentadas em destaque — são normalmente pouco exploradas, quando comparadas com as etapas posteriores. O enfoque desse estudo é dar maior atenção à etapa de pré-processamento. *Fonte: Elaborado pelo autor.*

para a extração de características latentes, também é proposto o uso de geração de imagens artificiais com o objetivo de rebalancear a base de imagens, possivelmente melhorando o modelo criado para a classificação.

De maneira sumária, **esta pesquisa busca melhorar a classificação de imagens, utilizando métodos de processamento com foco na extração de características latentes e no rebalanceamento de classes.** Os resultados preliminares obtidos, posteriormente apresentados na Seção 4.3, demonstram o potencial deste trabalho.

1.1 Contextualização

O grupo de pesquisa em Visualização, Imagens e Computação Gráfica (VICG), do Instituto de Ciências Matemáticas e de Computação (ICMC), tem atuado nas áreas de apoio para a classificação de coleções de imagens. Os trabalhos do grupo estão relacionados à visualização de informação com projeções multidimensionais e árvores (Joia et al., 2011), assim como à extração de características e classificação de coleções de imagens (Paiva et al., 2011). No que tange o processamento de imagens digitais, Picon et al. (2011) e Ponti (2013) focaram no pré-processamento para obter melhores resultados de classificação.

Paiva et al. (2011) mostraram que os espaços de características formados por cor e textura podem ser melhorados, porém há um limite até o qual as características podem ser transformadas, ou selecionadas, de forma a garantir a discriminação entre as classes. Tal projeto atua na investigação de métodos que permitam gerar espaços de características com maior discriminação entre as classes, facilitando a classificação.

Em outros dois trabalhos relacionados é possível ver a diferença na performance para problemas de classificação de imagens. No primeiro, os autores atingem acurácia acima de 98% na classificação de frutas após investigar alterações nos parâmetros de aquisição, realizar pré-processamento e obter a segmentação (Rocha et al., 2010). No segundo, os autores indicam que o método utilizado para obter a imagem em escala de cinza (comumente utilizada por algoritmos de extração), pode impactar significativamente a classificação final de diversas bases de imagens (Kanan e Cottrell, 2012).

Recentemente, Ponti et al. (2014) demonstraram que o uso de algoritmos de pré-processamento permite ao mesmo tempo obter vetores de características mais compactos e com maior capacidade de discriminação entre classes. Esta pesquisa pretende dar continuidade a esse trabalho, ao analisar técnicas de *deep learning*. Essas técnicas realizam múltiplas operações sobre imagens de entrada de forma a aprender quais operações permitem gerar características capazes de discriminar as classes (Bengio, 2009).

1.2 Relevância e hipóteses

Conforme anteriormente mencionado, muitos aspectos influenciam a performance da classificação de coleções de imagens. É comum encontrar bases cuja extração de características é considerada difícil, onde algoritmos canônicos de extração não conseguem extrair características que diferenciem bem as classes, prejudicando sua posterior classificação. Normalmente, tenta-se lidar com as particularidades das características extraídas através de transformações no espaço de atributos ou mesmo projetando classificadores

mais elaborados. Acredita-se que, ao invés disso, é importante investigar métodos de processamento e preparação de imagens antes da extração das características. Por isso, uma das hipóteses desse trabalho é que o uso desses métodos possa revelar características latentes – não visíveis nas imagens originais – que podem melhorar a acurácia da classificação.

Além disso, o desbalanceamento de classes é um obstáculo para uma classificação satisfatória, e por isso também será estudado. Em bases médicas, por exemplo, a quantidade de imagens relacionadas com uma doença rara é menor do que as imagens de pacientes sem a doença. Nessas situações, em que as imagens representam eventos importantes porém menos frequentes, o sistema de classificação pode ter problemas para lidar com a classe minoritária. A hipótese, nesse caso, é que a geração de imagens artificiais como preparação para a extração de características pode melhorar a acurácia da classificação, quando comparada à geração de exemplos artificiais no espaço de atributos. Ou seja, gerar novas imagens artificiais — que serão posteriormente reduzidas a atributos — pode apresentar melhores resultados para a classificação do que o *bootstrap* de atributos artificiais.

1.3 Objetivos

Destacar as contribuições

O objetivo desta pesquisa é explorar as etapas de processamento de imagens com o intuito de melhorar a discriminação entre classes de uma coleção de imagens. As hipóteses são:

hipóteses repetidas?

- A geração de imagens artificiais pode contribuir com o balanceamento entre classes (em se tratando de problemas de classes desbalanceadas), melhorando a acurácia de algoritmos de classificação, quando comparada à geração de exemplos artificiais no espaço de atributos;
- O uso de métodos de pré-processamento permite a extração de características latentes que aumentem a variância entre as classes, sem aumentar, no entanto, a variância intra-classe. Melhorando, assim, a classificação.

Com o objetivo de confirmar tais hipóteses, uma das propostas é analisar as características aprendidas por uma rede neural de convolução (CNN). Essa rede permite encontrar

as características mais relevantes da base de imagens, que os extractores de características canônicos não capturam. Isso porque ela possui uma hierarquia de camadas, desde a imagem original até uma etapa de classificação, com o objetivo de aprender qual o melhor processamento para as imagens de modo a melhor discriminá-las.

Após gerar as imagens artificiais, somente as imagens relevantes serão incluídas no treinamento. Para definir quais são as imagens que acrescentam informações na base, primeiramente será treinada uma máquina de Boltzmann restrita (RBM). A partir da matriz de características aprendida (memória associativa), é possível verificar se uma imagem acrescenta informações à base ou não. Por fim, conforme descrito na Seção 4.3 de resultados preliminares, será possível analisar operações simples e canônicas de pré-processamento de imagens.

Dados tais aspectos, pode-se então diferenciar os objetivos gerais e específicos:

Geral

Investigar os métodos de pré-processamento de imagens de forma a preparar uma coleção de imagens para a extração de características. Com isso, espera-se ao mesmo tempo obter características latentes e balancear o número de instâncias de diferentes classes.

Específicos

- Analisar o impacto da utilização de métodos canônicos de pré-processamento, como filtragem, adição de ruído e mistura, na classificação de bases de imagens. Investigar, também, o aprendizado de redes neurais de convolução, com o objetivo de observar quais são as características relevantes ao treiná-la com bases de imagens bem discriminadas em termos de cor, textura e forma;
- Modificar a base de imagens original de forma a tornar as características latentes visíveis. Com isso, pretende-se aumentar a variância entre as classes – antes da extração de características e classificação – com o auxílio dos métodos canônicos e CNN;
- Gerar imagens artificiais a partir das imagens pertencentes às classes minoritárias, compensando o desbalanceamento. Parte dessa tarefa já foi realizada e está descrita na Seção 4.3. O próximo passo é utilizar a matriz de características aprendida por máquinas de Boltzmann restritas para verificar se as imagens artificialmente geradas são relevantes para o aprendizado ou não, além de melhor escolher as imagens originais para a geração dessas imagens.

Considerando os objetivos aqui descritos, os resultados esperados desta pesquisa estão destacados na Seção 3.3.

1.4 Estrutura do documento

O conteúdo desta dissertação está estruturado como segue.

Capítulo 2: são conceituados os principais fundamentos necessários para o desenvolvimento desta pesquisa: pré-processamento de imagens, redes neurais de convolução, máquinas de Boltzmann restritas, extração de características e desbalanceamento de classes.

Capítulo 3: descreve-se a metodologia de pesquisa, assim como os resultados esperados.

O cronograma, com suas respectivas atividades e o tempo previsto para conclusão desta pesquisa, é destacado em seguida.

Capítulo 4: apresenta e discute os resultados preliminares, ressaltando quais são os próximos passos.

Fundamentos

2.1 Considerações iniciais

Neste capítulo são destacados os tópicos mais relevantes para a compreensão do estado da arte de processamento de imagens, com foco na preparação das imagens para a extração de características. O problema do desbalanceamento de classes e seu efeito na classificação satisfatória também são abordados, assim como a extração de características para compreender as propriedades extraídas das imagens. A área de *deep learning* é definida e as redes de convolução e máquinas de Boltzmann restritas são contextualizadas no âmbito desta pesquisa. Alguns trabalhos relacionados são utilizados como exemplo, com o objetivo de elucidar tais tópicos.

Inicialmente, a Seção 2.2 apresenta alguns dos principais métodos utilizados para o pré-processamento de imagens (i.e. remoção de ruído, realce de imagens e convolução), relevantes para o desenvolvimento desta pesquisa. Tendo como proposta melhor compreender o que são as características latentes, a Seção 2.4 exemplifica as operações de pré-processamento utilizadas para visualizar tais características em uma aplicação específica. A seção seguinte (2.5) destaca o uso de *deep learning* para o aprendizado de características e a Seção 2.6 aborda as máquinas de Boltzmann restritas como método para aprendizado da distribuição das imagens de entrada. A extração de características é brevemente definida na Seção 2.3. Por fim, o problema do desbalanceamento de classes é apresentado na Seção 2.7. Nessa seção, além de caracterizar o problema, são apresentadas

duas vertentes para solucioná-lo: sobreamostragem e subamostragem. Esses conceitos são necessários para a compreensão do capítulo de proposta desta dissertação.

2.2 Pré-processamento de imagens

Uma imagem digital I pode ser definida como uma função $f(x, y)$, onde x e y são as coordenadas cartesianas de um determinado ponto e f a intensidade (brilho) da imagem naquele ponto. Essa imagem é composta por finitos elementos chamados de pixels que podem ser diretamente acessados através de sua posição x e y . Digitalmente, uma imagem é representada por uma matriz de valores com M linhas e N colunas onde cada elemento representa a sua intensidade. Uma imagem colorida I do sistema RGB possui três canais de cores representantes das cores vermelha, verde e azul. Cada elemento $I(x, y)$ corresponde a uma tripla (r, g, b) de números, com $0 \leq r \leq 255$, $0 \leq g \leq 255$ e $0 \leq b \leq 255$, onde 0 é a intensidade de cor mais escura e 255 a mais clara. A combinação dessas intensidades resulta na cor do pixel (Gonzalez e Woods, 2007). A Figura 2.1 mostra uma visualização ampliada dos pixels de uma imagem digital.



Figura 2.1: Visualização pixelizada de uma imagem da base COREL-1000¹.
Fonte: Elaborado pelo autor.

¹Disponível em <http://wang.ist.psu.edu/docs/related/>

O processo de aquisição por um sistema de imageamento pode causar diversas imperfeições nas imagens, como pixels ruidosos, brilho inadequado e outras degradações. O pré-processamento de imagens é caracterizado por receber uma imagem de entrada e fornecer uma imagem de saída. Nessa etapa, efeitos indesejáveis podem ser eliminados e certas características realçadas (Figura 2.2). Considera-se que um determinado critério utilizado para uma imagem pode não ser o mais eficiente para outra, dependendo assim da área de aplicação.

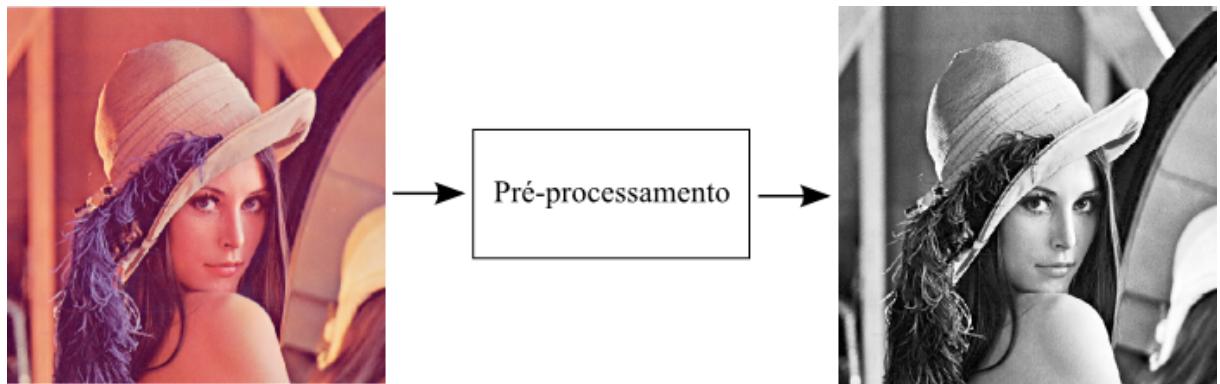


Figura 2.2: O pré-processamento de imagens é caracterizado por receber uma imagem como entrada e fornecer uma imagem de saída. Sobre a imagem RGB de entrada (à esquerda) foram realizadas operações de borramento, realce e de equalização de histograma. A imagem à direita é resultante dessas operações. *Fonte: Elaborado pelo autor.*

Assim, técnicas de pré-processamento tornam os dados mais adequados para posterior análise, ao eliminar ou reduzir problemas como ruídos e imperfeições. Em Ponti (2012), o autor relata que a utilização de métodos de restauração na etapa de pré-processamento da imagem, antes da segmentação, resultou em uma qualidade superior para todos os testes, com valores de erro e desvio padrão menores. No referido estudo, métodos de realce causaram perda de informação e por isso não são indicados para uso em imagens obtidas por microscópio. O método indicado para evitar a amplificação de ruído nessas imagens é o algoritmo iterativo Richardson-Lucy, que será apresentado na Seção 2.2.2.

Em contrapartida, Ahonen et al. (2006) propuseram uma representação para imagens faciais baseada em características de textura, sem utilizar pré-processamento. Este aparece somente como sugestão de trabalho futuro, como possível correção de problemas do sistema de captura (i.e. suavização causada pela captura fora de foco). O que implica que, apesar dos bons resultados, a melhoria com a utilização de pré-processamento não foi investigada. Pode-se imaginar, portanto, que o uso de pré-processamento pode melhorar

os resultados já obtidos, através do realce de textura e eliminação de imperfeições nas imagens.

Como exemplo do uso de métodos de pré-processamento, considere imagens de algas verdes obtidas por um microscópio de alta resolução. Essas algas são mergulhadas em um líquido que normalmente causa problemas de ruído e pouco contraste. Para a preparação dessas imagens, antes da extração de características, Borges et al. (2013) cita algumas etapas comuns em processamento de imagens digitais:

- As imagens – originalmente em RGB – são convertidas para uma escala de cinza;
- A dimensão da imagem é reduzida para diminuir o tempo de execução dos passos subsequentes de processamento;
- O contraste é “ajustado”, para aumentar a diferença das intensidades dos pixels da imagem e corrigir o brilho;
- A imagem é filtrada, removendo ruídos causados pelo processo de captura;
- O contorno é realçado, pois a forma é uma das características mais importantes para discriminar algas (e outros objetos);
- Por fim, o histograma é equalizado.

2.2.1 Filtragem espacial e convolução

Um filtro espacial, também conhecido como *kernel*, máscara ou janela, consiste em uma matriz de vizinhanças e uma operação a ser realizada nos pixels de uma imagem. A filtragem cria um novo pixel com as mesmas coordenadas do centro da vizinhança, contendo o valor resultante da filtragem. Dessa forma, a imagem filtrada contém os pixels resultantes da passagem do centro do filtro espacial por todos os pixels da imagem original (Gonzalez e Woods, 2007).

O processo de percorrer a imagem com um filtro espacial é chamado de correlação. A convolução, que pode ser definida como o operador $*$ na Equação (2.1), é o mesmo processo, mas com o filtro previamente rotacionado em 180° (Gonzalez e Woods, 2007).

$$\text{Mapa de características} = \text{imagem de entrada} * \text{filtro} \quad (2.1)$$

Os métodos de filtragem possuem como objetivo aperfeiçoar certos aspectos da imagem de entrada. Essa filtragem pode ser realizada no domínio da frequência ou no domínio

espacial. Um filtro de suavização típico no domínio espacial é o de Gaussiana, que resulta no borramento e redução de ruído, a fim de remover detalhes da imagem (Figura 2.3). Esse filtro utiliza uma função Gaussiana para calcular a transformação a ser realizada a cada pixel. A equação que representa a função Gaussiana em duas dimensões é definida por

$$G_\sigma(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}},$$

onde x, y são coordenadas de um determinado pixel da imagem e σ o desvio padrão que determina o raio da distribuição Gaussiana aplicada. Valores altos de variância fazem com que o resultado da função se aproxime da média.



Figura 2.3: Exemplo de filtragem gaussiana como operação de pré-processamento.
Fonte: Elaborado pelo autor.

2.2.2 Deconvolução

O processo de convolução, descrito na seção anterior, também pode ser definido como a passagem de uma imagem por um processo de aquisição que atue como um filtro de passa-baixas, resultando em uma imagem borrada. A deconvolução realiza a inversão desse borramento, o que pode facilitar a segmentação e detecção de características (Ponti, 2012). Para tal, é necessário conhecer previamente ou estimar a função que causou a degradação na imagem, geralmente denotada por $h(\mathbf{u})$, onde \mathbf{u} representa as coordenadas (x, y, z) para um sinal tridimensional.

Em casos mais simples é possível utilizar o filtro pseudo-inverso, obtendo o filtro a partir da transformada de Fourier da função h , denotada por H em

$$W(\mathbf{u}) = \begin{cases} H(\mathbf{u}), & H(\mathbf{u}) > \gamma \\ \gamma, & \text{caso contrário,} \end{cases}$$

onde o limiar γ utilizado é em geral um valor entre 0,0001 e 0,1. O filtro W é utilizado para realizar a inversão, no domínio da frequências, da imagem g borrada, obtendo a imagem restaurada a partir de

$$\hat{F}(\mathbf{u}) = \frac{G(\mathbf{u})}{W(\mathbf{u})},$$

onde \hat{F} é a transformada de Fourier da imagem restaurada, G é a transformada de Fourier da imagem borrada, e W é o filtro pseudo-inverso, que realiza a deconvolução.

Um outro exemplo de algoritmo de deconvolução é o Richardson-Lucy (Ponti et al., 2011), que utiliza um processo iterativo para recuperar uma imagem degradada que foi borrada por algum processo conhecido. Utiliza uma metodologia probabilística, baseada em EM-ML (*Expectation-Maximization Maximum Likelihood*), para encontrar uma imagem que maximize a probabilidade de se visualizar a imagem original sem degradação, considerando um modelo de ruído de Poisson. O algoritmo é descrito na Equação 2.2, onde n é o número da iteração.

$$\hat{f}_{n+1}(\mathbf{u}) = \left[\left(\frac{g(\mathbf{u})}{\hat{f}_n(\mathbf{u}) * h(\mathbf{u})} \right) * h(\mathbf{u}) \right] \times \hat{f}_n(\mathbf{u}). \quad (2.2)$$

Algoritmos iterativos como o Richardson-Lucy tem a vantagem de permitir soluções parciais, evitando amplificação de ruído.

2.2.3 Realce de imagens

O realce de imagens é o processo de modificar uma imagem para que se torne mais adequada para uma aplicação específica do que na sua forma original. É subjetivo, porque depende do sujeito que está analisando a imagem dissennir a qualidade desse realce (Gonzalez e Woods, 2007).

Na Figura 2.4 está demonstrado o efeito do algoritmo de *unsharp masking*, utilizando como borramento um filtro de média. Com o objetivo de realçar imagens, os passos deste método são:

1. Borramento da imagem original;
2. Cálculo da diferença entre a imagem suavizada e a original;
3. Soma dessa diferença à imagem original.



Figura 2.4: A imagem original, já em escala de cinza, foi realçada utilizando o método *unsharp masking*. *Fonte: Elaborado pelo autor.*

Um exemplo clássico de utilização de realce, é para compensar a variação de iluminação em diversas imagens. Em Gross e Brajovic (2003), os autores propuseram um algoritmo para o reconhecimento de faces invariante à iluminação. Eles ressaltam que, desconsiderando a variação da posição, a iluminação é o fator de maior impacto na aparência das faces. A luz varia durante o dia, entre um dia e outro e entre diferentes ambientes. Isso afeta o conjunto de imagens a ser analisado, que passa a conter imagens com diferentes contrastes, o que pode acentuar ou diminuir certas características faciais.

O contraste é a diferença de intensidade entre os níveis de maior e menor intensidade na imagem. Imagens com baixa resolução podem ser geradas a partir de uma iluminação pobre ou outros problemas com a captura. Dessa forma, o processo de “esticar” o contraste expande os níveis de intensidade da imagem (Gonzalez e Woods, 2007).

Explicar melhor histograma e k

É possível aumentar o contraste de uma imagem ao manipular o seu histograma h , que pode ser definido como

$$h(i_k) = n_k,$$

onde n_k é o número de pixels de intensidade i_k . Ao observar os histogramas de diferentes imagens é possível notar que imagens com alto contraste possuem um histograma com níveis próximos a uma distribuição uniforme. Isso permite que certas operações, como a equalização de histograma, obtenham o melhor contraste de uma imagem. Essa operação é caracterizada pela máxima variância do histograma e pode ser definida como

$$s_k = T(i_k) = \frac{L-1}{MN} \sum_{j=0}^k n_j, \quad (2.3)$$

onde L é o número de intensidades e MN as dimensões da imagem. A imagem de saída é obtida ao mapear cada pixel de intensidade i_k em um nível s_k , com i entre $[0, L-1]$, sendo $i = 0$ um pixel preto e $i = L-1$, branco (Gonzalez e Woods, 2007).

2.2.4 Restauração

Ao contrário do realce, a etapa da restauração é objetiva. Também procura melhorar os aspectos visuais de uma imagem, mas com base em modelos probabilísticos de degradação de imagens. Dessa forma, tendo-se um modelo de degradação, procura-se recuperar a imagem original (Gonzalez e Woods, 2007). Mas um problema comum em algoritmos de remoção de ruído é que alguns detalhes, como textura, irão sofrer alta suavização.

O objetivo dos algoritmos de remoção de ruído é recuperar a imagem original. Assim o modelo estatístico da imagem natural é crucial para a remoção de ruído. O tipo mais simples de ruído é o aditivo, que pode ser caracterizado como

$$p = p_0 + n,$$

onde p_0 é o valor real do pixel e n é a perturbação de ruído naquele pixel.

Um algoritmo alternativo para remoção de ruído é o de médias não locais. Isso porque pixels similares não necessariamente estão próximos em suas coordenadas cartesianas, assim, informações não locais podem ser utilizadas na redução de ruído. De acordo com Buades et al. (2005), dada uma imagem ruidosa $v = v(i)|i \in I$, o valor estimado é calculado como uma média ponderada de todos os pixels em uma mesma imagem com

$$v(i) = \sum_{j \in I} w(i, j)v(j),$$

onde os pesos $w(i, j)$ dependem da similaridade entre pixels.

2.2.5 Quantização

A maioria dos métodos de extração de características utiliza imagens de entrada em escala de cinza. Isso ocorre porque a complexidade de lidar com um pixel representado em três dimensões é muito maior do que em apenas uma dimensão. Assim, os métodos de quantização visam, de alguma forma, reduzir os canais de cores (24 bits) em apenas um (8 bits). Kanan e Cottrell (2012) demonstraram que os métodos para a quantização (conversão de uma imagem colorida para escala de cinza) influenciam a performance no reconhecimento de imagens. Eles também salientam que o método utilizado deveria estar claramente descrito nas publicações da área.

Em um trabalho recente (Ponti et al., 2014), com participação da autora desta dissertação, quatro métodos de quantização foram investigados. Foi constatado que os melhores métodos de conversão para escala de cinza antes da utilização dos descriptores de características a serem mencionados na Seção 2.3 são:

- Intensidade: método mais simples, consiste em computar a média entre os canais RGB da imagem a partir de

$$Q_{\text{Intensidade}} = \frac{1}{3}(R + G + B)$$

e então realizar a correção por *gamma*.

- Bits mais significativos (MSB): ao invés de realizar uma combinação linear dos canais de cores, ordena os bits dos canais coloridos em um único canal. Computa quantos bits de cada canal de cor contribuem para a imagem final e extrai os bits do código binário dos canais originais (Ponti e Escobar, 2013).

A Figura 2.5 apresenta a conversão na escala de cinza obtida com o uso destes métodos.

2.3 Extração de características

O objetivo da extração de características é descrever as informações visuais relevantes em um vetor de características. Esse vetor pode ser utilizado como entrada para um algoritmo de classificação de padrões. Como por exemplo, em aplicações que envolvem a classificação de algas, uma informação muito importante para a discriminação entre classes é a forma (Borges et al., 2013). Essas características devem salientar as diferenças entre imagens de classes distintas e suavizar possíveis diferenças de imagens da mesma classe. Algumas características, segundo Gonzalez e Woods (2007), são:



Figura 2.5: Conversão para a escala de cinza com os métodos de Intensidade e MSB.
Fonte: Elaborado pelo autor.

Textura: na sua descrição estatística, possui propriedades como: suavidade, aspereza e uniformidade. Um exemplo de medida para descrever a textura é a entropia.

Forma: representa os objetos em termos de suas características externas, como, por exemplo, a medida da curvatura.

Cor: considera a distribuição espacial de cores na imagem. O histograma de uma imagem pode descrever essa configuração de forma global.

Exemplos de métodos conhecidos capazes de descrever forma e outras características são: histogramas de orientação de gradiente (Wang et al., 2009), curvatura, descritores de Fourier, métodos baseados na detecção de SUSAN (Smith e Brady, 1997), Harris-Affine (Harris e Stephens, 1998) e diferença de Gaussianas (Lowe, 2004). Os descritores utilizados para a obtenção dos resultados preliminares da Seção 4.3 e que vão ser utilizados no desenvolvimento desta pesquisa estão abaixo descritos.

Histograma global de cor (GCH): calcula o histograma global dos níveis de intensidade da imagem. É a alternativa mais simples para representar as informações de uma imagem (Gonzalez e Woods, 2007). Produz um vetor de N dimensões, sendo N o número de intensidades.

Vetor de coerência de cor (CCV): captura informações sobre como as cores são organizadas em regiões conectadas, de acordo com um *threshold*. Classifica os pixels da imagem em coerentes e incoerentes, computa os respectivos histogramas e os concatena (Huang et al., 1997). Dessa forma, o vetor de características produzido possui $2N$ dimensões.

Classificação de pixels de borda e interior (BIC): computa dois histogramas, um para pixels definidos como borda e outro como interior. Se um pixel possuir a mesma cor que seus vizinhos, é pixel de interior; caso contrário, será pixel de borda. Os histogramas são concatenados, gerando um vetor de $2N$ dimensões (Stehling et al., 2002).

Auto-correlograma de cor (ACC): captura a correlação espacial entre cores idênticas. Computa a probabilidade de encontrar dois pixels com a mesma cor, a uma distância d um do outro (Pass et al., 1996). Neste estudo, são consideradas quatro distâncias: 1, 3, 5 e 7; resultando em um vetor com $4N$ características.

Haralick-6: extrai seis características a partir uma matriz de coocorrência: entropia, homogeneidade, contraste, correlação, probabilidade máxima e uniformidade. O vetor resultante possui 6 dimensões (Haralick et al., 1973).

2.4 Características latentes

Assim como o método de quantização se mostrou relevante na classificação, nesta dissertação são estudados diversos métodos de pré-processamento de imagens, como filtros de borramento e deconvolução, com o objetivo de obter imagens processadas que sejam mais bem caracterizadas para a etapa de classificação (ou seja, aumentando a variância entre as classes, sem aumentar a variância intra-classe). O enfoque está em como realçar determinadas características, como por exemplo cor, textura e forma. A esses atributos pode-se dar o nome de características latentes, não visíveis na imagem original. Identificar e realçar tais características é objetivo deste estudo. Essa abordagem se diferencia das técnicas multi-resolução, pois não pretende encontrar apenas características em versões de diferentes resoluções (convoluídas com filtros passa-baixa), e sim também em versões deconvoluídas ou transformadas por outros operadores.

Se uma das principais características que diferenciam classes de uma certa base utiliza a sua forma, é possível utilizar o método de diferença de Gaussianas para ressaltá-la. O método DoG (*Difference of Gaussians*) se baseia na diferença entre duas imagens filtradas. A operação comumente é feita usando $\sigma = \sqrt{2}$ e sua definição para dois níveis de filtragem é definida por

$$\begin{aligned} f_1(x, y) &= G_\sigma(f(x, y)) \\ f_2(x, y) &= G_{\sigma\sqrt{2}}(f_1(x, y)) \\ DoG_1(x, y, \sigma) &= f_2 - f_1 \end{aligned}$$

A Figura 2.6 demonstra uma possível execução de filtragem e restauração seguida pela detecção de bordas por DoG, aplicadas em uma base de imagens de algas verdes.

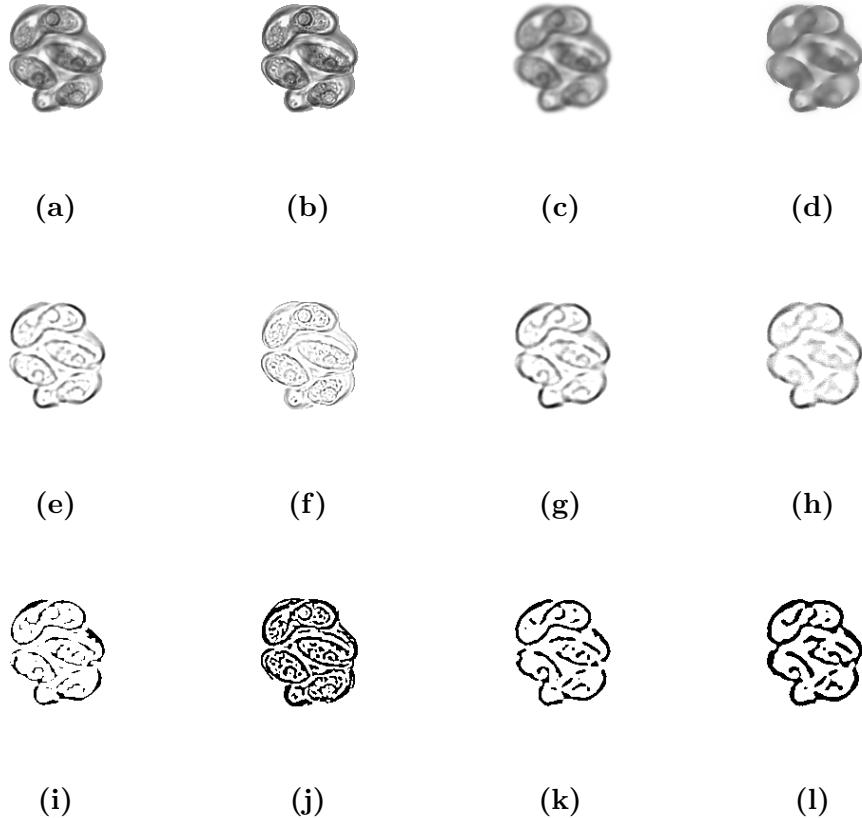


Figura 2.6: Características latentes de algas verdes. A primeira imagem (a) é uma imagem original segmentada de alga. As próximas colunas são imagens resultantes da deconvolução da imagem (coluna 2), filtragem Gaussiana (coluna 3) e filtragem Gaussiana seletiva (coluna 4). A primeira linha mostra versões diferentes de imagens de algas, a segunda linha exibe imagens resultantes da diferença de Gaussianas, e a terceira linha demonstra imagens binárias obtidas por limiarização das imagens contidas na segunda linha). *Fonte: Elaborado pelo autor.*

A imagem 2.6a é uma imagem original segmentada de alga. As próximas colunas são imagens resultantes da deconvolução da imagem (coluna 2), filtragem Gaussiana (coluna 3) e filtragem Gaussiana seletiva (coluna 4). As modificações apresentadas na primeira linha geram informações em diferentes planos axiais da imagem de microscopia. Imagens na segunda coluna representam uma versão deconvoluída das imagens originais, ressaltando a textura na superfície das algas, resultantes da diferença de Gaussianas. Já a terceira linha demonstra imagens binárias obtidas por limiarização das imagens da segunda linha, realçando as características da base da célula.

Acredita-se que ao manipular as imagens através de técnicas de pré-processamento, pode-se gerar imagens artificiais com características latentes realçadas, melhorando a extração de características. As redes neurais, que aprendem automaticamente essas características, estão descritas nas próximas seções.

2.5 Deep learning

A habilidade humana de reconhecimento de padrões em imagens é surpreendente. Os algoritmos de aprendizado de máquina e de reconhecimento de padrões tentam habilitar os computadores a aprender, baseando-se no modelo de aprendizado de seres humanos (George, 2008). Considerando que existem milhões de neurônios em cada córtex visual e que o cérebro humano é composto por cinco desses córtex que evoluíram durante milhões de anos, pode-se afirmar que a tarefa de algoritmos de reconhecimento de padrões em imagens não é simples (Nielsen, 2015).

A capacidade humana de reconhecer novos padrões está diretamente relacionada com a capacidade de generalização, que para tal, utiliza hierarquias (George, 2008). Nessa linha, o aprendizado profundo ou *deep learning* é caracterizado por explorar o aprendizado ao simular o funcionamento do cérebro humano. Essa área está diretamente relacionada com aprendizado de máquina e inteligência artificial e lida com o aprendizado através de múltiplas camadas.

Explicitar quais são as regras para aprender um determinado conceito pode se tornar impossível. No caso de um avião, por exemplo, “voar” pode ser uma regra decomposta em “possuir largura maior que altura” e “ser aerodinâmico”. Essas subdivisões geram múltiplos níveis que possuem maior complexidade e abstração, de maneira similar ao aprendizado por camadas. Uma rede neural artificial utiliza imagens como treinamento para automaticamente inferir quais são as regras para o reconhecimento. São chamadas de redes neurais profundas ou *deep neural networks* as redes que possuem uma estrutura de muitas camadas – duas ou mais ocultas (Nielsen, 2015). Assim, dada uma imagem como entrada, o problema é subdividido em problemas mais simples de serem resolvidos, podendo chegar ao nível de pixels isolados.

As redes neurais artificiais consistem em um método para solucionar problemas de forma a simular o comportamento do cérebro humano. Ao tentar uma determinada solução e errar, essas redes aprendem e podem tentar novamente. Ou seja, adquirem conhecimento através da experiência. Elas contém neurônios de entrada, ocultos e de saída. Aprender nesse contexto significa encontrar os pesos que fazem com que a rede neural exiba o comportamento esperado (Schmidhuber, 2014).

A simulação desse modelo inspirado biologicamente utilizada hoje é de LeCun e Bottou (1998) e chama-se Rede Neural de Convolução (CNN ou ConvNet). Eles simplificaram tal arquitetura para utilizar um algoritmo de retropropagação para o treino. Desde então, essas redes vêm sendo utilizadas para detecção, reconhecimento, restauração, remoção de ruído e segmentação de imagens e vídeos, além de sua aplicação em áudio. Um exemplo de utilização dessa rede inspirada no modelo de LeCun foi desenvolvida pela empresa Google, com o objetivo de detectar faces e placas de carros para proteger a privacidade nas imagens de StreetView (Frome et al., 2009).

Apesar de redes profundas representarem o estado da arte em visão computacional, um bom entendimento das suas propriedades ainda está faltando. Alguns artigos recentes como Mahendran e Vedaldi (2014), Zeiler et al. (2011) Zeiler e Fergus (2013) e Simonyan et al. (2013) introduzem técnicas utilizadas para analisar o comportamento e operações internas dessas redes ao visualizá-las. Esta pesquisa situa-se nesse viés, ao analisar as características latentes extraídas por uma rede neural de convolução.

Para o uso em bases desbalanceadas, as imagens utilizadas para o rebalanceamento de forma visual podem ser geradas após o estudo das características latentes, encontradas no treinamento da classe minoritária em uma CNN. Essas características também podem ser realçadas de forma a melhorar a classificação de imagens.

2.5.1 Redes de convolução

São um tipo de rede neural que utiliza uma operação chamada de convolução, previamente descrita na Seção 2.2.1. Pode ser entendida como sendo várias multiplicações de um filtro espacial pela imagem de entrada, resultando em um mapa de características ativadas. Esse filtro é um vetor de parâmetros capaz de aprender. Cada imagem possui seu conjunto de mapas de características, mas os filtros são comuns a todas as imagens. Dependendo dos valores do filtro, as características ativadas são diferentes. Nesse contexto, a camada de convolução consiste em muitas aplicações de convolução em paralelo, dado que um filtro é capaz de extrair apenas um tipo de característica (Bengio et al., 2014).

Basicamente, uma CNN é uma arquitetura que pode aprender características invariantes. Com múltiplas camadas, ela pode aprender multiníveis de características (LeCun et al., 2010). Ou seja, permite ao computador criar conceitos complexos a partir de conceitos simples. Como o conceito de *deep learning* enfatiza o uso de variáveis latentes, sugere que algoritmo de treinamento pode inventar os conceitos que precisa para representar determinada base de dados (Bengio et al., 2014).

Cada camada é composta de três estágios LeCun et al. (2010), representados na Figura 2.7:

Estágio de convolução: várias convoluções em paralelo para produzir um conjunto de ativações pré-sinápticas;

Estágio de detecção: função de ativação, como a unidade linear retificada ou a sigmoid;

Estágio de pooling: retorna uma representação invariante a pequenas translações da entrada. Um exemplo é utilizar o valor máximo entre vizinhos (conhecido como *max-pooling*).

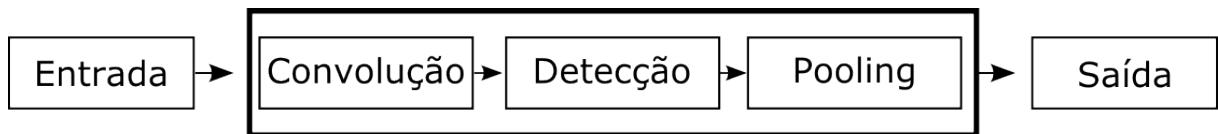


Figura 2.7: Componentes típicos de uma camada de uma rede neural de convolução. Nessa terminologia a rede possui camadas complexas que possuem estágios (Bengio et al., 2014). *Fonte: Elaborado pelo autor.*

De acordo com Bengio et al. (2014), durante a propagação são realizadas as convoluções e propagadas pelo resto da rede para então computar uma função de perda, que mede quão bem o sistema de aprendizado funcionou para cada exemplo. Na retropropagação, recebe-se um gradiente para atualizar os pesos. O gradiente descendente estocástico atualiza o sistema de aprendizagem com base no erro medido para um único exemplo. Apesar de a convergência ser mais ruidosa do que calcular a média sobre todos os erros, diminui-se um custo constante do cálculo de custo.

Normalmente, o classificador é a última camada totalmente conectada, que computa o produto de um vetor de características (Bengio et al., 2014). Mahendran e Vedaldi (2014) reportam que as camadas inteiramente conectadas podem ser invertidas a uma imagem resultante da composição de partes similares às encontradas na imagem original, mas não idênticas. Enfatizam também que todas as camadas de convolução mantém uma representação fiel da imagem. Essa característica permite a análise de quais atributos são relevantes para o aprendizado da base de imagens, tarefa crucial para esta pesquisa.

Zeiler et al. (2011) propuseram uma rede de deconvolução para a visualização das camadas, que pode ser vista como o caminho inverso de uma rede de convolução. Dessa forma, ao invés de mapear pixels em características, faz-se o contrário, permitindo a construção não supervisionada de representação de imagens hierárquicas, que podem, por exemplo, ser usadas para redução de ruído (Zeiler e Fergus, 2013). Tenta gerar o sinal de entrada dada a soma das convoluções dos mapas de características com os filtros

aprendidos. Apesar de destacar que, dado o mapa de características latentes, é possível sintetizar uma imagem, o artigo de Zeiler et al. (2011) não discorre sobre essa síntese.

2.6 Máquinas de Boltzmann restritas

Uma máquina de Boltzmann restrita (RBM) é uma rede neural estocástica que treina um modelo a partir dos vetores de entrada. Ela aprende os parâmetros que definem a distribuição sobre um conjunto de observações sem retropropagação e baseando-se em energia (Fischer e Igel, 2014).

Diferente de uma rede de Hopfield, ela agrupa probabilidades e encontra a mínima energia global. Faz isso através do arrefecimento simulado (*simulated annealing*), ou seja: em um primeiro momento, quando possui energia alta, aceita configurações piores; e conforme a energia é reduzida, detém-se a uma região e a explora melhor, até o equilíbrio térmico (Hinton et al., 2006).

Possuindo uma arquitetura muito mais simples que a CNN, é composta por duas camadas de neurônios: uma visível e outra oculta. Os pixels correspondem às unidades visíveis e os detectores de características às unidades ocultas. A sua restitividade se deve ao fato da falta de conectividade entre os neurônios de uma mesma camada, mas cada unidade visível é conectada a todas as unidades ocultas. Assim, a camada oculta, de detectores de características, modela a correlação entre os pixels.

A aprendizagem de uma RBM começa em um estado aleatório e atualiza seus pesos até encontrar uma distribuição que esteja em equilíbrio. Essa convergência ocorre quando o erro entre os exemplos treinados – fase positiva – e suas reconstruções – fase negativa – é menor que um certo limiar. Dessa forma, a cada iteração, um novo exemplo é treinado ao repetir iterativamente esses dois estágios e atualizar seus pesos (Hinton et al., 2006).

Fase positiva: fixa a camada visível e computa o valor dos neurônios ocultos. A probabilidade de um neurônio oculto ser ativado (se torne igual a 1) é dada pela função

$$p(h_j = 1) = \frac{1}{1 + e^{-(b_j + \sum_{i \in \text{vis}} v_i w_{ij})}}, \quad (2.4)$$

onde $p(h_j)$ é a probabilidade do neurônio h_j ser ativado, utilizando uma função de ativação sigmóide, e w_{ij} o peso entre a entrada i e o neurônio j .

A contribuição da fase positiva é computada para cada par de unidades a_{ij} , ao conferir se os dois neurônios (x_i e x_j) estão ativados por meio de

$$\text{Fase}_+(a_{ij}) = x_i \cdot x_j$$

Fase negativa: a partir dos valores computados na fase positiva, os neurônios visíveis são “reconstruídos” ($p(v_i)$) e os ocultos novamente computados ($p(h_{j'})$) a partir da função de probabilidade da Equação (2.4).

A contribuição da fase negativa é calculada da mesma forma que a contribuição positiva, com

$$Fase_-(a_{ij}) = x_i \cdot x_j$$

Atualização dos pesos: os pesos w_{ij} são ajustados considerando a diferença entre os neurônios visíveis reconstruídos e os valores fornecidos de entrada inicialmente (etapa conhecida como *contrastive divergence*):

$$w_{ij} = w_{ij} + L(Fase_+(a_{ij}) - Fase_-(a_{ij})),$$

onde L é a taxa de aprendizado. Quanto menor esse valor, melhor o treinamento e maior tempo até a convergência.

Essas redes também podem ser usadas como classificadores, ao treiná-las para modelar a relação entre a distribuição de entrada e seus respectivos rótulos (Fischer e Igel, 2014). Devido à capacidade das máquinas de Boltzmann restritas de aprender representações das imagens, pode-se utilizá-las para identificar se uma imagem é relevante para o aprendizado. Pode-se, por exemplo, utilizar apenas um neurônio, com a matriz de pesos representando uma memória associativa, para entender quais imagens são mais relevantes dentro de uma classe arbitrária. Dessa forma, também é possível avaliar a relevância da informação contida em uma imagem artificialmente gerada.

2.7 Desbalanceamento de classes

Nesta seção é definido o problema do desbalanceamento de classes e apresentados os trabalhos relacionados que possuem duas diferentes abordagens: sobreamostragem (*over-sampling*) e subamostragem (*under-sampling*).

O desbalanceamento de classes é identificado quando determinadas classes possuem um número muito maior de elementos do que outras. Em conjuntos de dados desbalanceados, as classes com mais elementos são chamadas de classes majoritárias, e as com menos elementos, de minoritárias.

cuidado ao dizer que não é um problema

O desempenho de algoritmos de Aprendizado de Máquina é prejudicado quando tratam de dados desbalanceados. Esses algoritmos tendem a favorecer a classificação de um novo

objeto à classe majoritária. Considera-se, então, que o problema do desbalanceamento de classes é um obstáculo para a classificação satisfatória. Porém, como apontado por Batista et al. (2004), o desbalanceamento não é o único responsável por reduzir o desempenho de algoritmos de aprendizagem. Eles sugerem que é possível haver uma ótima classificação mesmo contendo alto desbalanceamento na base de dados. Assim, a motivação do estudo de vários algoritmos para rebalanceamento não é apenas balancear os dados de treinamento, mas também remover elementos ruidosos para se obter uma melhor diferenciação entre as classes.

Os autores concluíram que o desbalanceamento por si só não é um problema, mas quando em conjunto com a sobreposição de classes pode diminuir significativamente a acurácia da classificação da classe minoritária. Os resultados também mostram que a poda de árvores de decisão raramente levou a alguma melhora na classificação. Em geral, os melhores resultados foram obtidos por algoritmos de *over-sampling*, os quais normalmente também levam a um maior número de regras de indução do que os dados originais.

Castro e Braga (2011) destacam que duas abordagens têm sido utilizadas para solucionar esse problema: pode-se utilizar o pré-processamento dos dados de forma a rebalancear as distribuições das classes ao reamostrar os dados; ou então modificar métodos de aprendizado, como adicionar funções de custo na classificação. Esta pesquisa tem como enfoque o pré-processamento dos dados, ao rebalancear as classes através da geração de imagens artificiais.

2.7.1 Sobreamostragem

Realizar uma sobreamostragem em um determinado conjunto de dados significa aumentar, utilizando alguma estratégia, o número de elementos desse conjunto. Em Chawla et al. (2002), a simples replicação de exemplos já existentes na classe minoritária não melhorou a classificação. Isso se deve ao reconhecimento de regiões muito específicas, causando *overfitting*.

O SMOTE (*Synthetic Minority Over-sampling Technique*) é uma técnica desenvolvida por Chawla et al. (2002) para rebalancear classes ao gerar artificialmente novos elementos, ao invés de apenas replicá-los. É aplicado sobre os vetores de características previamente extraídos, com operações de perturbação dos dados de treino (como rotação, por exemplo) no espaço de características, e não no espaço dos dados. A diferença entre o vetor de características de um elemento e do seu vizinho mais próximo é multiplicada por um número aleatório entre zero e um. Esse valor é adicionado ao vetor original, criando um novo elemento. Essa abordagem provoca a geração de um elemento entre os dois vetores

originais. Os exemplos sintéticos forçam uma região de decisão maior e mais geral para serem aprendidas como exemplos da classe minoritária.

Dessa forma, o SMOTE provê mais elementos para o classificador aprender, ao contrário da replicação de dados. Como trabalhos futuros, Chawla et al. (2002) apontam que diferentes estratégias para criar esses exemplos sintéticos podem melhorar a performance da classificação. Inclusive salientando exemplos que foram errôneamente classificados.

Uma variação desse algoritmo, denominada Borderline-SMOTE1 (Han et al., 2005), considera que elementos fora da linha de borda de cada classe pouco contribuem para a classificação. Por isso, propõe a geração de elementos sintéticos utilizando apenas elementos de borda. Considera que se os vizinhos mais próximos são da classe majoritária, o exemplo é ruído, e se há mais vizinhos da classe majoritária do que da minoritária, considera esse elemento como sendo de borda. Como trabalho futuro, destacam a necessidade de considerar diferentes estratégias para definir em quais elementos realizar o over-sampling.

2.7.2 Subamostragem

Ao contrário da sobreamostragem, a subamostragem visa diminuir o número de elementos de um determinado conjunto. A ideia é eliminar elementos da classe majoritária que estão distantes da fronteira de decisão, isso porque eles são considerados menos relevantes para a aprendizagem.

Métodos para remoção de exemplos da classe majoritária normalmente apresentam resultados piores do que métodos de sobreamostragem, conforme relatado por Batista et al. (2004) e (Japkowicz e Stephen, 2002). Um dos motivos pela preferência natural à sobreamostragem é o fato de que ao realizar subamostragem pode-se remover informações essenciais dos dados originais. Mas não há uma estratégia única que funcione melhor para todos os cenários.

2.8 Considerações finais

Deu-se destaque à discussão das etapas de pré-processamento e realce de características latentes, ambas foco deste estudo, assim como a geração de imagens artificiais para o balanceamento de classes. Este capítulo apresentou diversos métodos para exemplificação, além de trabalhos similares.

A extração de características foi abordada, apresentando os principais descritores utilizados nesta pesquisa. A lacuna destacada é que existem características não passíveis

de extração por descritores convencionais. Para isso, as redes de convolução são apresentadas, pois possuem capacidade de aprender as características relevantes das imagens de entrada. Justificando, assim, seu uso para análise das propriedades das bases de imagens. Podem também indicar possíveis operações para auxiliar na geração de imagens artificiais. Ainda, a memória associativa aprendida por máquinas de Boltzmann restritas pode ser indicadora de quais imagens geradas adicionam informações ao aprendizado. A geração dessas imagens visa rebalancear classes que diferem em número de imagens, e detalhes sobre esse problema também foram fundamentados nesse capítulo.

Esses fundamentos permitem compreender em que contexto esta dissertação de mestrado está inserida. O próximo capítulo abrangerá a proposta deste trabalho.

Proposta

3.1 Considerações iniciais

Neste capítulo está descrita a proposta de pesquisa desse mestrado. Primeiramente, a metodologia para o estudo e implementação da proposta é descrita. A seção de resultados esperados ressalta quais são os resultados que essa pesquisa almeja e, por fim, as atividades que essa dissertação engloba e seu respectivo cronograma são elencados.

3.2 Metodologia

Pesquisa bibliográfica:

1. Características latentes: são estudados diversos métodos de pré-processamento de imagens, como filtros de borramento e filtragem, com o objetivo de obter imagens processadas que sejam melhor caracterizadas para a etapa de classificação. O enfoque está em como realçar determinadas características, como, por exemplo, cor e textura, utilizando diversos algoritmos sobre as imagens originais.
2. Redes neurais: por representarem o estado da arte da classificação, reconhecimento e localização de objetos, as redes neurais de convolução são estudadas. Pretende-se utilizar a análise dos resultados do seu treinamento para identificar

as características relevantes em imagens. Já as máquinas de Boltzmann restritas são redes neurais mais simples, portanto convenientes para a verificação da relevância de uma imagem para o aprendizado.

3. Desbalanceamento de classes: esse problema é fundamentado em reconhecimento de padrões, e consiste em lidar com um conjunto de classes que possuem quantidades desiguais de imagens. Deve-se assim pesquisar métodos que visam equilibrar o número de imagens em cada classe.
4. Descritores: são investigados métodos capazes de descrever as propriedades das imagens, como histograma global de cor (GCH) (Gonzalez e Woods, 2007), vetor de coerência de cor (CCV) (Huang et al., 1997), classificação de pixels de borda e interior (BIC) (Stehling et al., 2002), auto-correlograma de cor (ACC) (Pass et al., 1996) e descritores de Haralick (Haralick et al., 1973).
5. Classificador de padrões: alguns classificadores fundamentados na literatura para a classificação de imagens são o Naive Bayes, OPF (*Optimum-Path Forest*), KNN (*K-Nearest Neighbor*), SVM (*Support Vector Machines*) e Softmax. A depender da performance do sistema após experimentos um destes será escolhido. É importante destacar que esse não é o foco deste estudo, que tem a maior contribuição na pesquisa do pré-processamento das imagens de forma a obter características relevantes e no rebalanceamento de classes com dados de informação visual.

Implementação: a biblioteca OpenCV (Intel, 2010) será utilizada para as funções gerais de carregar, processar, salvar e classificar imagens. A linguagem de programação para utilizar esta biblioteca e na qual esta pesquisa está sendo implementada é C++. Para a geração de gráficos das medidas estatísticas a linguagem de programação Python é utilizada. O código está disponível em <https://bitbucket.org/moacirponti/imagefeatureextraction/overview>.

Bases de imagens: considerando que os objetivos propostos possuem um viés genérico, os experimentos vão ser realizados em diversas coleções de imagens com o objetivo de estabelecer ou refutar as hipóteses levantadas.

Os resultados preliminares foram obtidos utilizando a base de imagens COREL¹, composta por fotografias que representam as classes: tribos africanas, praia, construções, ônibus, dinossauros, elefantes, flores, cavalos, montanhas e tipos de comidas. São 10 classes balanceadas com 100 imagens cada. Para fins de exemplificação, foram selecionadas imagens que representam essas classes na Figura 3.1.

¹Disponível em <http://wang.ist.psu.edu/docs/related/>



Figura 3.1: Base de imagens COREL-1000 utilizada. Estão representadas as 10 classes da base. *Fonte: Elaborado pelo autor.*

Experimentos: serão realizados diversos experimentos direcionados a explorar as etapas de pré-processamento, para melhorar a acurácia da classificação de bases de imagens. Como entrada são utilizadas imagens originais provenientes de diversas coleções disponíveis na literatura. Como resultado, serão calculadas medidas estatísticas da classificação dessas coleções após a alteração dessas imagens com os métodos de realce de características relevantes.

Análise dos dados: os experimentos realizados irão resultar em medidas estatísticas da classificação. A análise irá comparar a classificação das imagens originais com aquelas tratadas pelo método proposto. Ainda, o método de rebalanceamento de classes será comparado com técnicas disponíveis na literatura, como o SMOTE.

Forma de avaliação: a medida estatística mais comum para avaliação é a razão do número de acertos pela quantidade de imagens testadas. Essa medida, conhecida por acurácia, pode não refletir propriamente os resultados, em um cenário de bases desbalanceadas. Isso se deve ao fato de que se a classe minoritária não obtiver nenhum resultado correto e a classe majoritária tiver 100% de acertos, a acurácia normal poderá ser muito alta, mesmo considerando que nenhuma imagem da classe minoritária foi corretamente classificada. Dessa forma, considera que os erros são igualmente importantes. Mas em se tratando de bases desbalanceadas, deve-se diferenciar o erro em, por exemplo, diagnosticar um paciente doente – classe minoritária – como sendo saudável e um paciente saudável – classe majoritária – como estando doente (Batista et al., 2004). No primeiro caso, o paciente corre risco de diagnóstico tardil, enquanto o paciente saudável realiza outros testes para refutação.

Pode-se estender essa medida obtendo-se a acurácia k-fold: medida de acerto baseada na divisão do conjunto de objetos em teste e treinamento, realizando a repetição dos experimentos n vezes e obtendo a média e o desvio padrão. A

acurácia de cada experimento é obtida pela Equação 3.1, que considera problemas de desbalanceamento de classes.

$$Acc = 1 - \frac{\sum_{i=1}^c E(i)}{2c}, \quad (3.1)$$

onde c é o número de classes e $E(i) = e_{i,1} + e_{i,2}$ é o erro relativo a c , calculado por:

$$e_{i,1} = \frac{FP(i)}{N - N(i)} \quad \text{e} \quad e_{i,2} = \frac{FN(i)}{N(i)}, \quad i = 1, \dots, c,$$

onde $FN(i)$ (falsos negativos) são os exemplos pertencentes a i e incorretamente classificados, e $FP(i)$ (falsos positivos) são os exemplos erroneamente rotulados como i .

Uma outra medida para bases desbalanceadas é a medida-F1 (conhecida como *F1-Measure* ou *F1-Score* e apresentada na Equação (3.4)), que combina precisão e revocação como medida de efetividade da classificação (Garcia, 2009). A precisão (Equação 3.2) é a medida da exatidão: dos exemplos classificados como positivos, quantos realmente são. E a revocação (Equação 3.3) é a medida de completude: quantos exemplos positivos foram corretamente classificados como tal.

$$P = \frac{VP}{VP + FP}, \quad (3.2)$$

onde VP são os exemplos positivos corretamente classificados.

$$R = \frac{VP}{VP + FN} \quad (3.3)$$

$$F1 = 2 \frac{PR}{P + R} \quad (3.4)$$

A partir dessas medidas, o teste estatístico de Friedman pode ser usado para determinar se há diferença significante em uma amostra de resultados gerados (García et al., 2010). As performances dos algoritmos são analisados e um *rank* é atribuído para cada conjunto de dados. Ele considera que a hipótese nula a ser testada é que não há diferença estatística relevante entre as observações. Para analisar se o teste da hipótese é significativo, pode ser utilizado o p-valor, que indica o quão estatisticamente significante o resultado é: quanto menor o seu valor, maior a evidência contra a hipótese nula (geralmente o limiar utilizado é de 0,05).

Por fim, a distância de Mahalanobis também pode ser utilizada: antes e depois da geração artificial de imagens, calcular a distância entre a média das classes e a variância dentro das classes (De Maesschalck et al., 2000). Ela se baseia na correlação entre as variáveis e pode ser definida por

$$D_m(x_i) = \sqrt{(x_i - \mu)C^{-1}(x_i - \mu)^T},$$

onde x_i é um vetor de valores, μ a média e C a matriz de covariância.

3.3 Resultados esperados

Os resultados esperados são relacionados às áreas de **processamento de imagens e reconhecimento de padrões**. Espera-se obter uma comprovação das hipóteses levantadas por essa pesquisa. Os resultados são esperados em duas vertentes:

1. *Pré-processamento* de imagens que caracterizem melhor aspectos de suas classes, aumentando a variância entre as classes quando comparado com as imagens originais.
2. *Geração artificial de imagens* de classes minoritárias de forma a compensar o desbalanceamento natural das bases de dados.

Em ambos os casos pretende-se melhorar a classificação, validando-a através do cálculo da medida-F1. A análise das características aprendidas por uma rede neural de convolução será realizada ao executar o treinamento com bases específicas que destaquem propriedades como cor, textura e forma. Além disso, os resultados serão obtidos a partir da escolha de quais imagens adicionam informação ao conjunto de treino. As redes RBM serão utilizadas para este fim. Bases naturalmente não balanceadas serão testadas e seus resultados avaliados.

3.4 Atividades e cronograma previsto

As principais atividades contempladas no desenvolvimento dessa pesquisa de mestrado são as seguintes:

1. Integralização dos créditos das disciplinas do Programa de Mestrado do ICMC/USP;
2. Revisão bibliográfica;

3. Estudo e implementação da geração de imagens artificiais para corrigir o desbalanceamento de classes;
4. Estudo e implementação de métodos para obtenção de características latentes;
5. Projetar e realizar experimentos com diversas bases de dados utilizando os métodos propostos e posterior validação;
6. Escrita científica para a produção do exame de qualificação, dissertação de mestrado e artigos científicos.

Tabela 3.1: Duração de cada atividade a partir de 24/02/2014.

Atividade	2014		2015		2016
	1º Sem.	2º Sem.	1º Sem.	2º Sem.	1º Sem.
1	■■■■■	■■■■■			
2		■■■■■	■■■■■	■■■■■	
3		■■■■■	■■■■■	■■■	
4				■■■■■	■■■■■
5		■■■■■	■■■■■	■■■■■	
6		■■■■■	■■■■■	■■■■■	■■■■■

3.5 Considerações finais

A proposta desta pesquisa foi apresentada, descrevendo a sua metodologia. Foi dado destaque aos resultados esperados e à forma de avaliação, descrevendo as medidas estatísticas a serem utilizadas. O cronograma previsto para a realização deste mestrado foi destacado, elencando as atividades e suas respetivas durações. O próximo capítulo apresentará os resultados preliminares.

Resultados Preliminares

Experimentos: - Descrição das bases - Descrição das ferramentas/técnicas/pacotes - Descrição do protocolo - Apresentação dos resultados - Discussão dos resultados

Qual adição de ruído? Qual nível?

Variação gradual de parâmetros para identificar o que causa perdas/ganhos

4.1 Considerações iniciais

Este capítulo apresenta os resultados preliminares obtidos. Primeiramente, é apresentada a descrição do experimento realizado, ressaltando os métodos de extração de características, quantização e classificação utilizados. Além disso, o fluxo de operações para a realização do experimento é descrito. Em seguida, os resultados são propriamente ilustrados, ao indicar que a geração de imagens artificiais é promissora para o cenário de bases desbalanceadas. Por fim, as atividades futuras são destacadas.

4.2 Descrição do experimento

Algumas pesquisas sobre os efeitos da sobreamostragem e geração de exemplos artificiais em dados de aprendizado de máquina já foram realizadas (Kuncheva, 2004; Chawla et al., 2002). O método mais divulgado na literatura é conhecido como SMOTE (*Synthetic*

Minority Over-sampling Technique). Este método propõe a geração de exemplos artificiais a partir dos vetores de características originais das classes minoritárias. Não há registro conhecido de um estudo dessas técnicas em dados de informação visual para o rebalanceamento de classes.

Assim, foi proposta a geração de novas imagens a partir de operações como adição de ruído, borramento, mistura e combinação das imagens originais. Tais operações estão exemplificadas na Figura 4.1, utilizando a classe “praia” da base de imagens naturais COREL-1000. A partir das imagens originais — primeira linha da figura — são geradas imagens artificiais por meio das operações citadas, resultando nas imagens da segunda linha da figura.



Figura 4.1: Geração de imagens artificiais para o rebalanceamento de classes. A partir das imagens originais mostradas na primeira linha, são geradas imagens artificiais por meio de: borramento, adição de ruído, mistura e combinação. Os resultados dessas operações estão demonstrados na segunda linha, em ordem. *Fonte: Elaborado pelo autor.*

Os descritores de características utilizados para os resultados foram apresentados na Seção 2.3. Considerando que em um experimento anterior o melhor resultado foi atribuído à quantização com o método de Intensidade para o extrator Haralick e MSB para os outros, apenas esses testes foram aprofundados (tópico anteriormente discutido na Seção 2.2.5). Neste experimento, o classificador KNN foi utilizado, com $K = 1$. Inicialmente o classificador Naive Bayes foi explorado, apresentando melhora na acurácia ao apenas replicar as imagens. Esse comportamento não é desejado em um classificador para a avaliação de rebalanceamento de classes. O código desenvolvido para esses resultados preliminares

está disponível em <https://bitbucket.org/moacirponti/imagefeatureextraction/overview>.

4.2.1 Fluxo de operações

Para a realização desse experimento, iniciou-se com uma base originalmente balanceada e foram realizadas as seguintes operações:

1. Diminuir logaritmicamente o número de imagens de uma das classes, de modo a obter uma base desbalanceada;
2. Para cada estágio de desbalanceamento, realizar três experimentos:
 - (a) A classificação direta, sem nenhuma operação de rebalanceamento;
 - (b) A operação de SMOTE, após a extração de características e antes da classificação;
 - (c) Rebalanceamento da classe minoritária com a geração de imagens antes da extração de características.
3. Extraír as características com os descritores: ACC, BIC, CCV, GCH e Haralick6; e os quantizadores: Intensidade, Gleam, Luminância e MSB;
4. Classificar com KNN utilizando validação cruzada por *repeated random-subsampling*;
5. Executar os passos de 2 a 4 no mínimo 10 vezes para cada par de extrator e quantizador;
6. Calcular a matriz de confusão, a acurácia balanceada, a medida-F e o teste de Friedman para os resultados encontrados;
7. Gerar os gráficos para visualização dos resultados.

4.2.2 Geração das imagens artificiais

As etapas para a geração das imagens artificiais, passo 2c da seção anterior, foram:

1. Particionar a classe minoritária em conjuntos de treino e teste;
2. Selecionar uma imagem aleatoriamente do conjunto de treino;

3. Selecionar uma operação aleatória entre: borramento, adição de ruído, *unsharp mask*, mistura ou composição;
- 3.1. Caso seja selecionada a composição: encontrar uma outra imagem aleatória, selecionar um quadrante dessa imagem e novamente uma operação entre: borramento, adição de ruído, *unsharp mask* ou mistura;
4. Aplicar essa operação na imagem previamente selecionada e adicionar essa imagem gerada ao conjunto de treino;
5. Repetir os passos 2 a 4 até que as classes estejam igualmente balanceadas.

4.3 Resultados

Este estudo preliminar apresentou evidências experimentais de que, em problemas de duas classes (apresentadas na Figura 4.2), pode haver ganho estatístico da medida-F ao gerar imagens, quando comparado à geração de exemplos artificiais no espaço de atributos (ou seja, depois que as características já foram extraídas das imagens). Essa melhoria pode ser notada na Figura 4.3, que apresenta a relação da medida-F com a taxa de balanceamento, utilizando: as imagens originais, a geração de exemplos com SMOTE e as imagens geradas. Para essa configuração, foi utilizado o descritor de características ACC com a conversão em escala de cinza por MSB e a operação de pré-processamento por combinação. As classes “praia” e “montanha” foram escolhidas por serem as classes que possuem maior dificuldade de diferenciação, havendo alta taxa de sobreposição de intensidades de cores e texturas, conforme testes realizados.



Figura 4.2: Classes “praia” (primeira linha) e “montanha” (segunda linha) da base de imagens COREL-1000. *Fonte: Elaborado pelo autor.*

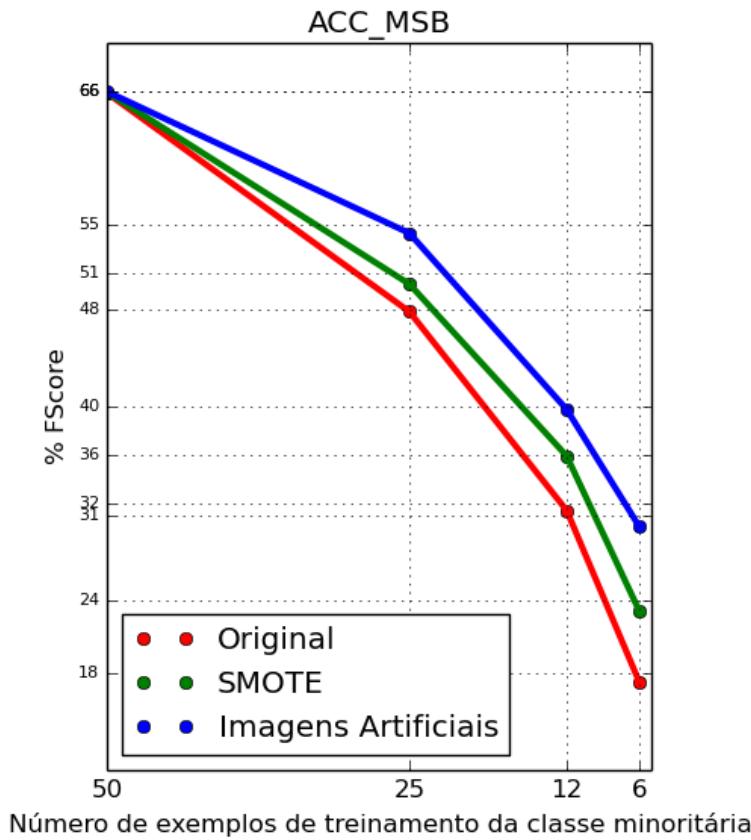


Figura 4.3: Resultado obtido com a operação de combinação apresentada na Figura 4.1. Apresenta-se a relação da medida-F com a taxa de balanceamento utilizando: as imagens originais, a geração de exemplos com SMOTE e as imagens geradas artificialmente.

Fonte: Elaborado pelo autor.

Também foi possível notar que algumas operações não provocaram a melhora da classificação. A operação de adição de ruído para geração artificial, a posterior extração utilizando CCV e a quantização por MSB, destacou-se como o pior resultado, apresentado na Figura 4.4. Outros casos que não obtiveram o resultado esperado envolveram as operações de borramento e de *unsharp masking*.

Após a realização dos testes, as operações que melhor se destacaram foram: utilizar todas as operações, apenas mistura e apenas composição. E as operações que resultaram em uma classificação pior do que o uso do SMOTE foram: utilizar apenas borramento, ruído ou *unsharp masking*. Com o teste estatístico de Friedman foi possível verificar que o ACC foi o extrator que melhor se beneficiou das características geradas; e CCV e GCH os

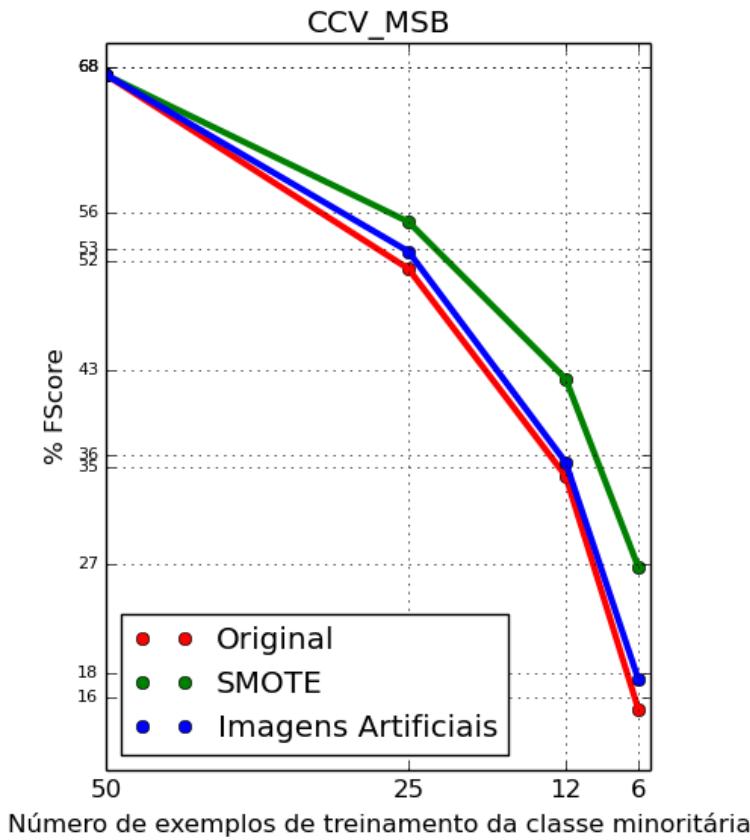


Figura 4.4: Piores resultados, obtidos com a adição de ruído. Apresenta-se a relação da medida-F com a taxa de balanceamento utilizando as imagens originais, o SMOTE e as imagens artificiais geradas. *Fonte: Elaborado pelo autor.*

menos beneficiados. A Tabela 4.1 apresenta os *rankings* encontrados por este teste para todas as execuções das melhores operações. O p-valor computado corresponde a $4.24E^{-11}$, assim a hipótese nula de que não há diferença entre as execuções foi rejeitada. Vale destacar que para algumas execuções, o teste de Friedman retornou o *ranking*: geração artificial (1), SMOTE (2) e imagens originais (3), ou seja, sem que SMOTE e a geração artificial concorressem pela mesma posição, diferente da tabela apresentada.

Tabela 4.1: Posição média dos algoritmos utilizando Friedman

Algoritmos	Posição
Original	3.0000
Smote	1.6136
Artificial	1.3863

Em outro experimento, utilizou-se as cópias das imagens de treino para rebalancear, sem realizar nenhuma operação de pré-processamento (método conhecido como SRS - *Simple Random Sampling*). A Figura 4.5 mostra as respectivas medidas-F encontradas. É possível notar que a cópia dessas imagens não adiciona nenhuma informação nova para o aprendizado.

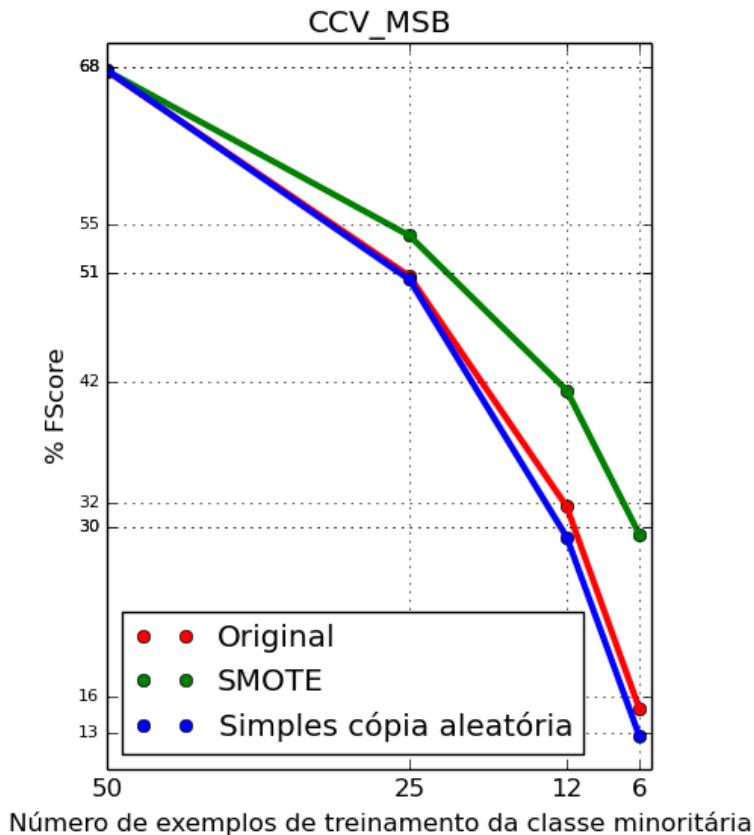


Figura 4.5: Simples replicação de exemplos sem realizar nenhuma operação de pré-processamento. É possível verificar que não foi adicionada nenhuma informação relevante para o aprendizado. *Fonte: Elaborado pelo autor.*

4.4 Trabalhos futuros

O treinamento de uma rede neural de convolução¹ foi realizado, utilizando as classes “praia” e “montanha”, balanceadas, da base COREL-1000. A classificação sobre este treinamento obteve $\approx 80\%$ de acurácia, enquanto que utilizando os extratores padrões

¹<http://caffe.berkeleyvision.org/>

foi possível atingir apenas $\approx 69\%$. Isso reforça a proposta de analisar quais são as características latentes que esse tipo de rede neural consegue extrair. Para essa análise vão ser utilizadas bases discriminadas quanto às propriedades de textura, cor e forma.

Além de analisar o processamento realizado por uma rede de convolução para a classificação das imagens, uma rede RBM também será treinada para análise da sua memória associativa. As imagens artificialmente geradas foram adicionadas no conjunto de treino sem verificação da sua relevância, o que pode ter prejudicado a classificação. A memória associativa aprendida com o treinamento de uma máquina de Boltzmann restrita pode vir a auxiliar no entendimento dessas imagens como relevantes ou não. Além disso, pode servir como escolha para qual imagem original utilizar, ao invés do método aleatório utilizado nos resultados preliminares.

4.5 Considerações finais

Com os experimentos realizados foi possível notar que a geração de imagens artificiais pode gerar novas informações para a classificação das imagens. O que indica que um estudo mais aprofundado de quais operações podem ser aplicadas nas imagens originais auxilie o cenário de bases desbalanceadas.

Dessa forma, esse capítulo também apresentou as próximas tarefas a serem realizadas. Foi destacada a análise das redes de convolução para identificar quais características latentes são automaticamente extraídas. Apesar de algumas operações de pré-processamento terem gerado imagens que melhoraram a classificação, algumas não causaram melhora. Isso indica que a análise da relevância da informação contida em imagens deve melhorar esse resultado. A memória associativa, aprendida com uma máquina de Boltzmann restrita, deve ser capaz de indicar se uma determinada imagem é relevante para o aprendizado.

Referências Bibliográficas

- AHONEN, T.; HADID, A.; PIETIKÄINEN, M. Face description with local binary patterns: application to face recognition. *IEEE transactions on pattern analysis and machine intelligence*, v. 28, n. 12, p. 2037–2041, 2006.
- BATISTA, G. E.; PRATI, R. C.; MONARD, M. C. A study of the behavior of several methods for balancing machine learning training data. *ACM Sigkdd Explorations Newsletter*, v. 6, n. 1, p. 20–29, 2004.
- BENGIO, Y. Learning Deep Architectures for AI. *Foundations and Trends in Machine Learning*, v. 2, n. 1, p. 1–127, 2009.
- BENGIO, Y.; GOODFELLOW, I. J.; COURVILLE, A. Deep learning, book in preparation for MIT Press, 2014.
- BORGES, V.; OLIVEIRA, M. C.; FERREIRA, T. G.; VIEIRA, A. A. Feature Extraction and Interactive Visualization to Assist Green Algae Taxonomic Classification. In: *XXVI SIBGRAPI - Conference on graphics, patterns and images*, Arequipa, Peru, 2013, p. 4.
- BUADES, A.; COLL, B.; MOREL, J. M. A Review of Image Denoising Algorithms, with a New One. *Multiscale Modeling & Simulation*, v. 4, n. 2, p. 490–530, 2005.
- CASTRO, C. L.; BRAGA, A. P. Aprendizado supervisionado com conjuntos de dados desbalanceados. *Sba Controle & Automação*, v. 22, n. 5, p. 441 – 446, 2011.
- CHAWLA, N. V.; HALL, L. O.; BOWYER, K. W. SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, v. 16, p. 321–357, 2002.

- DE MAESSCHALCK, R.; JOUAN-RIMBAUD, D.; MASSART, D. The Mahalanobis distance. *Chemometrics and Intelligent Laboratory Systems*, v. 50, n. 1, p. 1–18, 2000.
- FISCHER, A.; IGEL, C. Training restricted Boltzmann machines: An introduction. *Pattern Recognition*, v. 47, n. 1, p. 25–39, 2014.
- FROME, A.; CHEUNG, G.; ABDULKADER, A.; ZENNARO, M.; BISSACCO, A.; ADAM, H.; NEVEN, H.; VINCENT, L. Large-scale privacy protection in Google Street View. In: *2009 IEEE 12th International Conference on Computer Vision*, IEEE, 2009, p. 2373–2380.
- GARCIA, E. A. Learning from Imbalanced Data. *IEEE Transactions on Knowledge and Data Engineering*, v. 21, n. 9, p. 1263–1284, 2009.
- GARCÍA, S.; FERNÁNDEZ, A.; LUENGO, J.; HERRERA, F. Advanced nonparametric tests for multiple comparisons in the design of experiments in computational intelligence and data mining: Experimental analysis of power. *Information Sciences*, v. 180, n. 10, p. 2044–2064, 2010.
- GEORGE, D. *How the brain might work: a hierarchical and temporal model for learning and recognition*. Dissertation, Stanford University, 2008.
- GONZALEZ, R. C.; WOODS, R. E. *Digital Image Processing*. 3 ed. Prentice-Hall, 2007.
- GROSS, R.; BRAJOVIC, V. An image preprocessing algorithm for illumination invariant face recognition. *Audio and Video-Based Biometric Person Authentication*, p. 10–18, 2003.
- HAN, H.; WANG, W.-Y.; MAO, B.-H. Borderline-SMOTE: A new over-sampling method in imbalanced data sets learning. *Advances in intelligent computing*, v. 17, n. 12, p. 878–887, 2005.
- HARALICK, R. M.; SHANMUGAM, K.; DINSTEIN, I. Textural Features for Image Classification. *IEEE Transactions on Systems, Man, and Cybernetics*, v. 3, n. 6, p. 610–621, 1973.
- HARRIS, C.; STEPHENS, M. A combined corner and edge detector. In: *Proceedings of the Alvey Vision Conference*, Alvey Vision Club, 1998, p. 147—152.

- HINTON, G.; OSINDERO, S.; TEH, Y. W. A fast learning algorithm for deep belief nets. *Neural computation*, 2006.
- HUANG, J.; KUMAR, S. R.; MITRA, M.; ZHU, W.-J.; ZABIH, R. Image indexing using color correlograms. In: *Computer Society Conference on Computer Vision and Pattern Recognition*, IEEE, 1997, p. 762–768.
- INTEL OpenCV: open source computer vision library. 2010.
- JAPKOWICZ, N.; STEPHEN, S. The class imbalance problem : A systematic study. *Intelligent data analysis*, v. 6, n. 5, p. 429–449, 2002.
- JOIA, P.; PAULOVICH, F. V.; COIMBRA, D.; CUMINATO, J. A.; NONATO, L. G. Local Affine Multidimensional Projection. *IEEE Transactions on Visualization and Computer Graphics*, v. 17, n. 12, p. 2563–2571, 2011.
- KANAN, C.; COTTRELL, G. W. Color-to-grayscale: does the method matter in image recognition? *PloS one*, v. 7, n. 1, p. e29740, 2012.
- KUNCHEVA, L. *Combining pattern classifiers: methods and algorithms*. John Wiley & Sons, 2004.
- LECUN, Y.; BOTTOU, L. Gradient-based learning applied to document recognition. In: *Proceedings of the IEEE*, 1998, p. 2278—2324.
- LECUN, Y.; KAVUKCUOGLU, K.; FARABET, C. Convolutional networks and applications in vision. In: *International Symposium on Circuits and Systems*, IEEE, 2010, p. 253–256.
- LOWE, D. G. D. G. Distinctive image features from scale-invariant keypoints. *International Journal of Computer Vision*, v. 60, n. 2, p. 91–110, 2004.
- MAHENDRAN, A.; VEDALDI, A. Understanding deep image representations by inverting them, arXiv preprint arXiv:1412.0035, 2014.
- NIELSEN, M. A. *Neural Networks and Deep Learning*. Determination Press, 2015.
- PAIVA, J. G. S.; FLORIAN, L.; PEDRINI, H.; TELLES, G. P.; MINGHIM, R. Improved similarity trees and their application to visual data classification. *IEEE Transactions on Visualization and Computer Graphics*, v. 17, n. 12, p. 2459–2468, 2011.

- PASS, G.; ZABIH, R.; MILLER, J. Comparing images using color coherence vectors. In: *Proceedings of the fourth ACM international conference on Multimedia*, New York, USA: ACM Press, 1996, p. 65–73.
- PICON, C. T.; ROSSI, I.; JR, M. P. P. Análise da classificação de imagens por descritores de cor utilizando várias resoluções. In: *Workshop of Undergraduate Works*, SIBGRAPI, 2011.
- PONTI, M.; ESCOBAR, L. Compact color features with bitwise quantization and reduced resolution for mobile processing. In: *Global Conference on Signal and Information Processing*, Austin, TX, Estados Unidos, 2013, p. 751–754.
- PONTI, M.; MASCARENHAS, N.; FERREIRA, P.; SUAZO, C. Three-dimensional noisy image restoration using filtered extrapolation and deconvolution. *Signal, Image and Video Processing*, v. 7, n. 1, p. 1–10, 2011.
- PONTI, M.; NAZARÉ, T.; THUMÉ, G. Image quantization as a dimensionality reduction procedure in color and texture feature extraction, submitted to Neurocomputing, 2014.
- PONTI, M. P. Microscope volume segmentation improved through non-linear restoration. *Nature-Inspired Computing Design, Development, and Applications*, 2012.
- PONTI, M. P. Segmentation of Low-Cost Remote Sensing Images Combining Vegetation Indices and Mean Shift. *Geoscience and Remote Sensing Letters*, v. 10, n. 1, p. 67–70, 2013.
- ROCHA, A.; HAUAGGE, D. C.; WAINER, J.; GOLDENSTEIN, S. Automatic fruit and vegetable classification from images. *Computers and Electronics in Agriculture*, v. 70, n. 1, p. 96–104, 2010.
- SCHMIDHUBER, J. Deep learning in neural networks: An overview. *Neural Networks*, p. 88, 2014.
- SIMONYAN, K.; VEDALDI, A.; ZISSERMAN, A. Deep Inside Convolutional Networks: Visualising Image Classification Models and Saliency Maps. In: *ICLR Workshop*, 2013, p. 1–8.
- SMITH, S. M.; BRADY, J. M. SUSAN—a new approach to low level image processing. *International journal of computer vision*, v. 23, n. 1, p. 45–78, 1997.
- STEHLING, R. O.; NASCIMENTO, M. A.; FALCÃO, A. X. A compact and efficient image retrieval approach based on border/interior pixel classification. In: *Proceedings*

- of the eleventh international conference on Information and knowledge management*, New York, USA: ACM Press, 2002, p. 102–109.
- WANG, X.; HAN, T. X.; YAN, S. An HOG-LBP human detector with partial occlusion handling. *IEEE 12th International Conference on Computer Vision*, 2009.
- ZEILER, M. D.; FERGUS, R. Visualizing and Understanding Convolutional Networks. *Computer Vision–ECCV 2014*, p. 818–833, 2013.
- ZEILER, M. D.; TAYLOR, G. W.; FERGUS, R. Adaptive deconvolutional networks for mid and high level feature learning. In: *International Conference on Computer Vision*, IEEE, 2011, p. 2018–2025.